Минобрнауки России

Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Волгоградский государственный технический университет»

Факультет Электроники и вычислительной техники

Кафедра ЭВМ и системы

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
к курсовой работе (проекту)

по дисциплине Системы обработки больших данных

на тему Исследование данных организации с использованием Apache Spark

Студент Храмцов Владимир Александрович
(фамилия, имя, отчество)

Группа ЭВМ – 1.3

Руководитель работы (проекта) _____ Кравченя П.Д.
(подпись и дата подписания) (инициалы и фамилия)

Члены комиссии:

_____ _____
(подпись и дата подписания) (инициалы и фамилия)

_____ _____
(подпись и дата подписания) (инициалы и фамилия)

_____ _____
(подпись и дата подписания) (инициалы и фамилия)

Нормоконтролер _____ _____
(подпись, дата подписания) (инициалы и фамилия)

Волгоград 20__ г.

Минобрнауки России

Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Волгоградский государственный технический университет»

Факультет Электроники и вычислительной техники

Направление (специальность) 09.04.01

Кафедра ЭВМ и систем

Дисциплина Системы обработки больших данных

Утверждаю
Зав. кафедрой Андреев А.Е.

«_____» _____20 ___ г.

ЗАДАНИЕ
на курсовую работу (проект)

Студент Храмцов Владимир Александрович
(фамилия, имя, отчество)

Группа ЭВМ – 1.3

1. Тема: Исследование данных организации с использованием Apache Spark

Утверждена приказом от «_____» _____ 20___ г. № _____

2. Срок представления работы (проекта) к защите «___»_____20_ г.

3. Содержание расчетно-пояснительной записки: _____

4. Перечень графического материала: _____

5. Дата выдачи задания «_____» _____20 ___ г.

Руководитель работы (проекта)_____ Кравченя П.Д.
подпись, дата инициалы и фамилия

Задание принял к исполнению_____ Храмцов В.А.
подпись, дата инициалы и фамилия

СОДЕРЖАНИЕ

ВВЕДЕНИЕ 4
1 ПОДГОТОВКА И ПЕРВИЧНАЯ ОБРАБОТКА ДАТАСЕТА LENDING CLUB LOANS DATA 5
1.1 Описание исходного датасета и отбор признаков 5
1.2 Очистка и подготовка данных 6
1.3 Промежуточные результаты первой части 7
1.4 Выводы по первой главе 7
2 РАЗВЕДОЧНЫЙ АНАЛИЗ ПОДГОТОВЛЕННОГО ДАТАСЕТА 9
2.1 Загрузка таблицы и первичный контроль качества 9
2.2 Анализ временной динамики по `issue_year` 9
2.3 Анализ категориальных признаков 11
2.4 Анализ количественных признаков 15
2.5 Анализ корреляционной структуры 18
2.6 Сохранение итогового результата 19
2.7 Выводы по второй главе 19
ЗАКЛЮЧЕНИЕ 21
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 22

ВВЕДЕНИЕ

Актуальность курсовой работы обусловлена постоянным ростом объёмов финансовых данных и необходимостью применения распределённых инструментов обработки для их хранения, очистки и анализа. Современные кредитные датасеты содержат большое количество записей и признаков, часть которых требует предварительного преобразования, фильтрации и унификации перед выполнением содержательного анализа. В таких условиях использование Apache Spark, HDFS и Apache Iceberg позволяет организовать полный цикл работы с данными: от чтения исходного набора до построения агрегатов и сохранения результатов в структурированном виде. В качестве объекта исследования в работе выбран датасет Lending Club Loans Data, а вычислительная среда построена на основе Spark, HDFS и Iceberg.

Целью курсовой работы является выполнение разведочного анализа датасета Lending Club Loans Data с использованием средств распределённой обработки данных, а также формирование подготовленного аналитического набора, пригодного для дальнейшего исследования.

Для достижения поставленной цели в работе решаются следующие задачи:

— загрузка данных из HDFS;

— изучение структуры исходного набора и отбор ключевых признаков;

— приведение признаков к корректным числовым и временным типам;

— удаление дубликатов и некорректных записей;

— формирование производных признаков;

— сохранение очищенного набора в Iceberg;

— выполнение агрегированного и визуального анализа подготовленной таблицы;

— интерпретация выявленных закономерностей;

1 ПОДГОТОВКА И ПЕРВИЧНАЯ ОБРАБОТКА ДАТАСЕТА LENDING CLUB LOANS DATA

1.1 Описание исходного датасета и отбор признаков

Объектом исследования выбран датасет Lending Club Loans Data, содержащий сведения о кредитах, выданных платформой Lending Club. В исходном варианте набор включает большое число признаков, однако в первой части работы для упрощения анализа и повышения наглядности были оставлены только десять базовых столбцов: `id`, `loan_amnt`, `term`, `int_rate`, `grade`, `annual_inc`, `issue_d`, `loan_status`, `purpose` и `dti`. Такой набор позволил сохранить ключевую финансовую и временную информацию о каждом кредите, не перегружая модель данных второстепенными атрибутами.

id	loan_amnt	term	int_rate	grade	annual_inc	issue_d	loan_status	purpose	dti
38098114	15000.0	60 months	12.39	C	78000.0	Dec-2014	Fully Paid	debt_consolidation	12.03
36805548	10400.0	36 months	6.99	A	58000.0	Dec-2014	Charged Off	credit_card	14.92
37842129	21425.0	60 months	15.59	D	63800.0	Dec-2014	Fully Paid	credit_card	18.49
37612354	12800.0	60 months	17.14	D	125000.0	Dec-2014	Current	car	8.31
37662224	7650.0	36 months	13.66	C	50000.0	Dec-2014	Charged Off	debt_consolidation	34.81
37822187	9600.0	36 months	13.66	C	69000.0	Dec-2014	Fully Paid	debt_consolidation	25.81
37741884	2500.0	36 months	11.99	B	89000.0	Dec-2014	Fully Paid	home_improvement	13.77
37854444	16000.0	60 months	11.44	B	109777.0	Dec-2014	Fully Paid	debt_consolidation	11.63
36804663	23325.0	36 months	14.31	C	72000.0	Dec-2014	Charged Off	credit_card	27.03
37642222	5250.0	36 months	11.44	B	26000.0	Dec-2014	Fully Paid	debt_consolidation	14.36
37701596	10000.0	36 months	11.99	B	90000.0	Dec-2014	Charged Off	debt_consolidation	8.44
37800722	12975.0	36 months	17.86	D	60000.0	Dec-2014	Charged Off	house	22.42
37682226	17000.0	36 months	13.66	C	75000.0	Dec-2014	Fully Paid	debt_consolidation	23.63
37712169	21075.0	60 months	21.99	E	55000.0	Dec-2014	Current	debt_consolidation	29.5
37742129	6000.0	36 months	10.49	B	120000.0	Dec-2014	Fully Paid	home_improvement	6.87
37742142	2000.0	36 months	14.99	C	32200.0	Dec-2014	Fully Paid	credit_card	22.14
36520573	3000.0	36 months	10.49	B	60000.0	Dec-2014	Fully Paid	medical	9.54
37854423	2000.0	36 months	15.99	D	37000.0	Dec-2014	Fully Paid	other	16.19
37822018	2000.0	36 months	14.31	C	52000.0	Dec-2014	Fully Paid	other	5.98
37752109	13550.0	60 months	19.99	E	40000.0	Dec-2014	Current	debt_consolidation	16.23

only showing top 20 rows

Рисунок 1 — Пример записей исходного датасета

После загрузки набора и первичного просмотра было выполнено преобразование признаков. Числовые поля `loan_amnt`, `annual_inc` и `dti` были приведены к типу `double`. Поле `int_rate`, изначально хранившееся как строка с символом процента, очищалось от `%` и преобразовывалось к числовому типу. Из строкового признака `term` извлекалось число месяцев в новый столбец

term_months. Из даты выдачи issue_d формировался временной признак issue_date, а также производные поля issue_year и issue_month. Кроме того, вводился бинарный признак is_default, принимающий значение 1 для проблемных состояний займа и 0 для остальных случаев.

1.2 Очистка и подготовка данных

```
root
 |-- id: string (nullable = true)
 |-- loan_amnt: double (nullable = true)
 |-- term: string (nullable = true)
 |-- int_rate: double (nullable = true)
 |-- grade: string (nullable = true)
 |-- annual_inc: double (nullable = true)
 |-- issue_d: string (nullable = true)
 |-- loan_status: string (nullable = true)
 |-- purpose: string (nullable = true)
 |-- dti: double (nullable = true)
 |-- term_months: integer (nullable = true)
 |-- issue_date: date (nullable = true)
 |-- issue_year: integer (nullable = true)
 |-- issue_month: integer (nullable = true)
 |-- is_default: integer (nullable = false)
```

Рисунок 2 — Используемые типы данных

Следующим этапом стала очистка данных. В ноутбуке были удалены дубликаты по идентификатору займа id, а также отфильтрованы записи с пустыми значениями в ключевых аналитических полях. Дополнительно были введены логические ограничения на допустимые значения признаков: сумма кредита должна быть больше нуля, годовой доход — положительным, процентная ставка — находиться в разумном диапазоне, а показатель dti не должен выходить за границы допустимых значений.

Такая очистка позволила устранить записи, которые могли бы исказить последующий анализ распределений и агрегатов. Итогом первой части стало формирование более устойчивого и однородного датафрейма.

После очистки набор данных был записан в Apache Iceberg. Для этого использовалась база данных `khramtsov_database`, а таблица была сохранена под именем `sobd_lab1_lending_club_table`. Дальнейшая работа второй главы выполнялась уже не по исходному CSV, а по этой Iceberg-таблице, что позволило избавиться от повторного чтения и повторной очистки исходного файла.

1.3 Промежуточные результаты первой части

Сформированный набор после первой части содержит как исходные, так и вычисленные признаки: `loan_amnt`, `term`, `int_rate`, `grade`, `annual_inc`, `issue_d`, `loan_status`, `purpose`, `dti`, а также `term_months`, `issue_date`, `issue_year`, `issue_month` и `is_default`. Пример строк показывает, что данные уже представлены в аналитически удобном виде: сумма кредита и ставка имеют числовой формат, дата выдачи нормализована до формата даты, а бинарный индикатор дефолта задаёт основу для вычисления долей проблемных займов.

Таким образом, первая часть работы фактически выполняет роль слоя предобработки и нормализации данных.

1.4 Выводы по первой главе

В первой главе был реализован полный цикл подготовки исходного датасета Lending Club Loans Data к последующему анализу. Исходный файл был прочитан из HDFS, для анализа были выбраны наиболее значимые финансовые и временные признаки, выполнено преобразование строковых полей в числовые и временные типы, сформированы производные признаки и про-

ведена очистка от некорректных записей. Результатом главы стало создание таблицы `sobd_lab1_lending_club_table` в базе `khramtsov_database`, которая послужила основой для расширенного разведочного анализа во второй главе.

```
database_name = "khramtsov_database"
table_name = "sobd_lab1_lending_club_table"
```

```
spark.sql(f"CREATE DATABASE IF NOT EXISTS spark_catalog.{database_name}")
```

```
DataFrame[]
```

```
spark.sql(f"DROP TABLE IF EXISTS spark_catalog.{database_name}.{table_name}")

df.writeTo(
    f"spark_catalog.{database_name}.{table_name}"
).using("iceberg").create()
```

```
for table in spark.catalog.listTables(database_name):
    print(table.name)
```

```
sobd_lab1_lending_club_table
sobd_lab1_lending_club_processed
```

```
df_table = spark.table(f"{database_name}.{table_name}")
df_table.show(10)
```

```
+------+---------+----------+--------+-----+----------+--------+--------------------+------------------+-----+----------+----------+----------+----------+----------+
|    id|loan_amnt|      term|int_rate|grade|annual_inc| issue_d|         loan_status|           purpose|  dti|term_months|issue_date|issue_year|issue_month|is_default|
+------+---------+----------+--------+-----+----------+--------+--------------------+------------------+-----+----------+----------+----------+----------+----------+
| 54734|  25000.0| 36 months|   11.89|    B|   85000.0|Aug-2009|          Fully Paid|debt_consolidation|19.48|        36|2009-08-01|      2009|         8|         0|
| 61390|   4000.0| 36 months|    7.88|    A|  148000.0|Feb-2010|          Fully Paid|       credit_card|16.98|        36|2010-02-01|      2010|         2|         0|
| 65419|  16000.0| 36 months|    6.89|    A|   72000.0|Jun-2015|             Current|  home_improvement|23.43|        36|2015-06-01|      2015|         6|         0|
| 70686|   5000.0| 36 months|    7.75|    A|   70000.0|Jun-2007|Does not meet the...|             other| 8.81|        36|2007-06-01|      2007|         6|         0|
| 72197|   3900.0| 36 months|    9.33|    B|   98000.0|Aug-2007|Does not meet the...|             other| 10.0|        36|2007-08-01|      2007|         8|         0|
| 87023|   7500.0| 36 months|   13.75|    E|   22000.0|Jun-2007|          Fully Paid|debt_consolidation|14.29|        36|2007-06-01|      2007|         6|         0|
| 91023|   1900.0| 36 months|    9.64|    B|  100000.0|Jul-2007|Does not meet the...|debt_consolidation| 10.0|        36|2007-07-01|      2007|         7|         0|
| 92402|   5000.0| 36 months|     8.7|    B|   75000.0|Jul-2007|          Fully Paid|       credit_card|15.55|        36|2007-07-01|      2007|         7|         0|
|106216|   2000.0| 36 months|   14.38|    E|   40000.0|Jul-2007|Does not meet the...|             other|15.57|        36|2007-07-01|      2007|         7|         0|
|112323|   3500.0| 36 months|   10.28|    C|   20000.0|Jul-2007|          Fully Paid|            moving|  1.5|        36|2007-07-01|      2007|         7|         0|
+------+---------+----------+--------+-----+----------+--------+--------------------+------------------+-----+----------+----------+----------+----------+----------+
only showing top 10 rows
```

Рисунок 3 — Загрузка данных в БД

2 РАЗВЕДОЧНЫЙ АНАЛИЗ ПОДГОТОВЛЕННОГО ДАТАСЕТА

Во второй главе выполняется более подробный анализ уже подготовленного датасета, сформированного в первой части. Целью этого этапа является исследование структуры, распределений и зависимостей внутри очищенного набора, а также интерпретация ключевых признаков, связанных с характеристиками кредита, его статусом и вероятностью проблемного исхода.

В ноутбуке выполняются проверка схемы и размера данных, анализ временного признака `issue_date`, категориальных признаков `loan_status`, `grade`, `purpose`, количественных признаков `loan_amnt`, `int_rate`, `annual_inc`, `dti`, расчёт корреляций и сохранение финальной обработанной таблицы.

2.1 Загрузка таблицы и первичный контроль качества

В Spark считывается Iceberg-таблица `spark_catalog.khramtsov_database.s` После загрузки выполняются просмотр первых строк, анализ схемы датафрейма и пересчёт количества записей. Затем из набора удаляются полные дубликаты, а для отдельных признаков вводится функция оценки количества пропусков. Такой подход позволяет убедиться, что анализ проводится над уже очищенными и согласованными данными.

2.2 Анализ временной динамики по `issue_year`

Одним из центральных результатов второй части является агрегированный анализ по году выдачи кредита. Для каждого года рассчитывались число выданных займов, средняя сумма кредита, средняя процентная ставка и доля проблемных займов. Полученные результаты показывают выраженный рост объёма кредитования в период с 2007 по 2015 год: количество займов увеличивается с 597 записей в 2007 году до более чем 421 тыс. записей в 2015 году. Одновременно с этим возрастает и средняя сумма кредита: если в

начале рассматриваемого периода она составляла около 8,3 тыс., то к середине 2010-х годов достигает уровня более 15 тыс. Это свидетельствует не только о масштабировании кредитного портфеля, но и об увеличении среднего размера выдаваемых займов.

Динамика средней процентной ставки также имеет содержательную интерпретацию. На ранних этапах ставка держится вблизи 12%, затем поднимается до 14,53% в 2013 году, после чего несколько снижается. Это может указывать на изменение структуры заёмщиков и кредитной политики платформы: в периоды активного расширения портфеля в систему попадало больше заёмщиков с более высоким риском, что отражалось в повышении средней ставки. После 2013 года снижение средней ставки при сохранении высоких объёмов выдачи может свидетельствовать о частичной стабилизации портфеля.

Особенно важным является анализ показателя `default_rate`. Если в 2007 году доля проблемных займов составляла 0,0737, то к 2014 году она достигает 0,1685, то есть возрастает более чем в два раза. Таким образом, рост кредитования сопровождался и ростом кредитного риска. Это позволяет сделать вывод о том, что расширение портфеля происходило не только за счёт увеличения числа клиентов, но и за счёт более рискованных кредитных сегментов. Следовательно, анализ по `issue_year` показывает одновременно три тенденции: увеличение объёма кредитования, рост средней суммы займа и ухудшение риск-профиля в отдельные периоды развития платформы.

issue_year	loans_cnt	avg_loan_amnt	avg_int_rate	default_rate
2007	597	8283.25	11.85	0.0737
2008	2353	8810.81	12.05	0.1024
2009	5159	9818.8	12.44	0.112
2010	12454	10504.83	11.98	0.1186
2011	21714	12047.21	12.22	0.1518
2012	53367	13461.71	13.64	0.162
2013	134814	14707.41	14.53	0.1544
2014	235629	14870.16	13.77	0.1685
2015	421083	15240.32	12.6	0.1577
2016	434216	14732.16	13.04	0.1078
2017	324130	14660.64	13.38	0.0297

Рисунок 4 — Анализ по issue_year

2.3 Анализ категориальных признаков

Категориальный признак `loan_status` позволяет оценить структуру кредитного портфеля по состоянию займов. Во второй части по этому признаку вычислялись количество записей, средняя сумма кредита, средняя ставка, средний доход заёмщика и средний показатель `dti`. Полученные результаты показывают, что наибольшую долю портфеля составляют займы со статусами `Current` и `Fully Paid`, то есть либо ещё обслуживаемые, либо уже успешно погашенные. При этом проблемные статусы, такие как `Charged Off`, `Late (31-120 days)` и `Late (16-30 days)`, характеризуются более высокой средней процентной ставкой и более высоким значением `dti`. Например, для `Charged Off` средняя ставка составляет 15,74%, тогда как для `Fully Paid` — 12,91%; средний `dti` также выше у проблемных займов. Это подтверждает, что дефолтные и просроченные кредиты в среднем связаны с более высокой долговой нагрузкой и более дорогими условиями кредитования.

Рисунок 5 — Распределение займов по статусам

Дополнительно видно, что заёмщики с проблемными статусами имеют в среднем меньший годовой доход, чем клиенты со статусом `Current`. Так, для `Current` средний доход составляет 79,627,33, а для `Charged Off` — 69,263,04. Это позволяет сделать вывод, что более низкий доход и более высокая долговая нагрузка могут быть связаны с повышенной вероятностью проблемного исхода займа. В совокупности признак `loan_status` демонстрирует качественное разделение портфеля на более устойчивые и более рискованные сегменты.

loan_status	loans_cnt	avg_loan_amnt	avg_int_rate	avg_annual_inc	avg_dti
Current	788081	15108.58	12.81	79627.33	18.97
Fully Paid	646627	14037.84	12.91	76791.39	17.29
Charged Off	168033	15385.48	15.74	69263.04	19.99
Late (31-120 days)	23744	15831.76	15.68	74458.55	20.29
In Grace Period	10463	16680.59	15.23	77939.34	19.84
Late (16-30 days)	5782	16379.22	15.48	77487.83	19.85
Does not meet the credit policy. Status:Fully Paid	1965	8849.73	13.99	72013.0	14.11
Does not meet the credit policy. Status:Charged Off	751	9510.49	14.59	69773.22	14.28
Default	70	16136.43	15.15	73474.69	20.58

Рисунок 6 — Доходы заемщиков по статусе кредита

Аналогичный подход был применён к признаку `grade`, который отражает кредитную категорию займа. Для каждой категории рассчитывались объём наблюдений, средняя сумма кредита, средняя ставка, средний доход и доля проблемных займов. Полученные результаты хорошо согласуются с экономической логикой: при переходе от категории A к категории G средняя

процентная ставка возрастает с 7,1% до 27,79%, а доля проблемных займов увеличивается с 0,0374 до уровня около 0,31. Особенно заметен рост риска при переходе от категорий B и C к D, E и F. Это означает, что признак `grade` действительно хорошо отражает кредитное качество заёмщика: чем хуже категория, тем выше и стоимость кредита, и вероятность проблемного исхода.

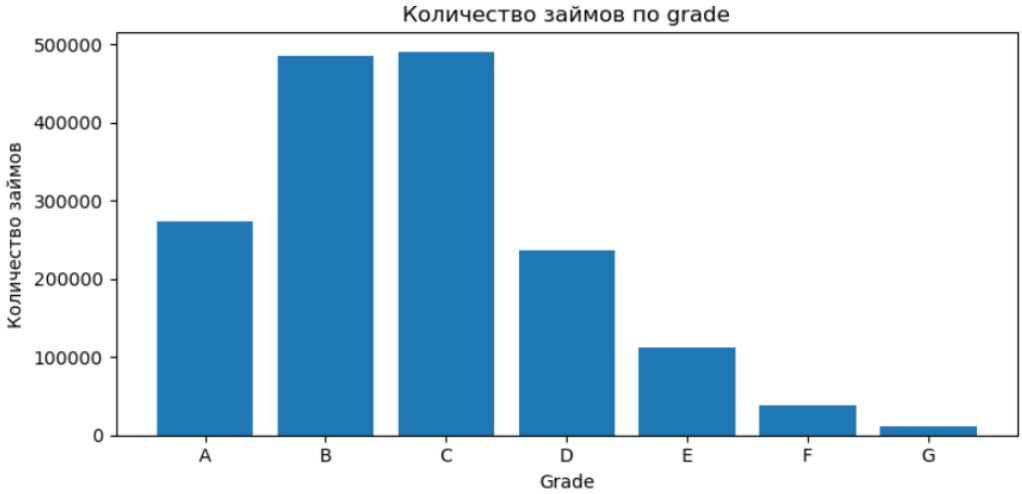

Рисунок 7 — Количество займов

Интересно также, что средняя сумма займа по мере ухудшения категории в целом растёт: от 14,030,53 для A до 20,344,05 для G. Это может указывать на то, что более рискованные заёмщики нередко берут более крупные кредиты, что дополнительно усиливает потенциальные потери в случае дефолта. При этом средний доход для категории A заметно выше, чем для большинства более рискованных категорий, что ещё раз подтверждает связь между финансовой устойчивостью клиента и качеством кредита.

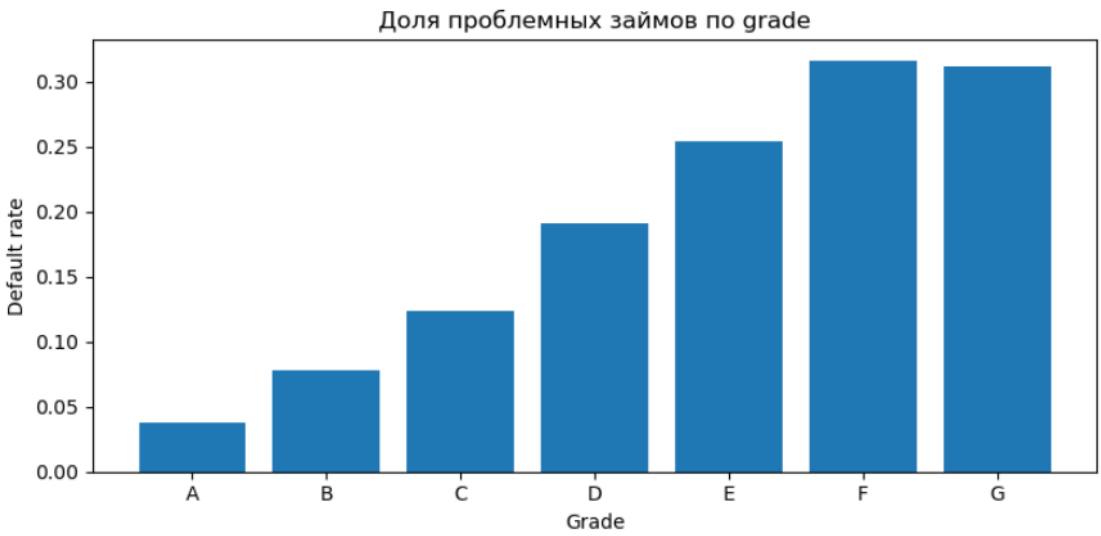

Рисунок 8 — Доля проблемных займов

Признак `purpose` использовался для анализа целей кредитования. Во второй части строилась агрегированная статистика по целям кредита, включая количество займов, среднюю сумму, среднюю ставку и долю проблемных кредитов. Наиболее массовой целью кредита оказалась `debt_consolidation`, на которую приходится 955,047 записей. Далее следуют `credit_card` и `home_improvement`. Это означает, что основная часть портфеля связана не с инвестиционными или специализированными потребностями, а с рефинансированием и перераспределением уже существующей долговой нагрузки.

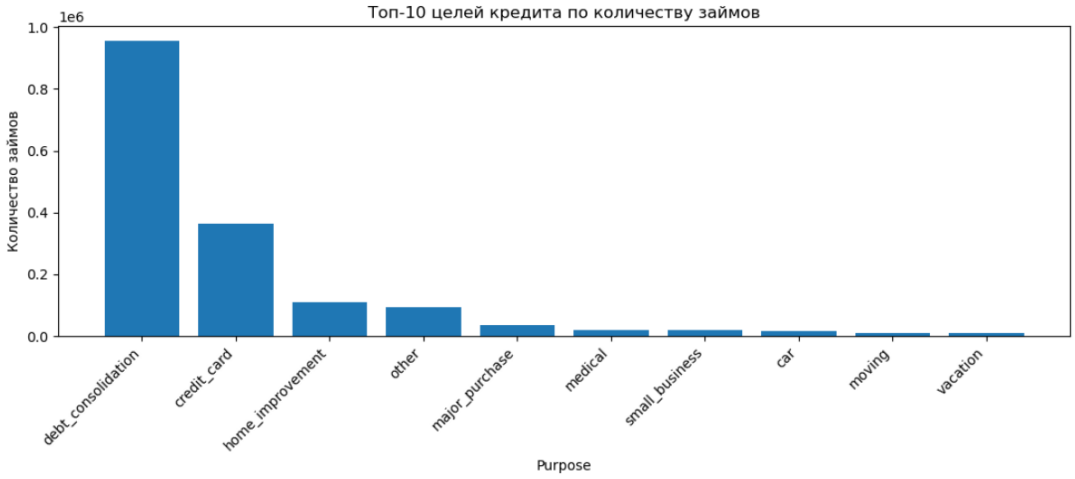

Рисунок 9 — Топ 10 целей по кредиту

По уровню риска цели кредита заметно различаются. Наиболее высокая доля проблемных займов наблюдается у `small_business` (0,1881), а также у `renewable_energy`, `house` и `moving`. Напротив, относительно низкая доля дефолтов характерна для `car` (0,0865), `credit_card` (0,1008) и `home_improvement` (0,1015). Это позволяет сделать вывод, что не все цели кредита одинаково рискованны: займы, связанные с малым бизнесом или переездом, демонстрируют более высокий уровень нестабильности, тогда как более стандартные потребительские направления оказываются статистически устойчивее.

2.4 Анализ количественных признаков

В главе были детально рассмотрены количественные признаки `loan_amnt`, `int_rate`, `annual_inc` и `dti`. Для каждого из них в ноутбуке рассчитывались описательные статистики, а затем строились графики распределения. По признаку `loan_amnt` анализировались типичный размер кредита, вариативность значений и наличие выбросов. По признаку `int_rate` изучалось распределение процентных ставок, что даёт представление о том, в каких диапазонах сосредоточена основная масса кредитов. Признак `dti` использовался для оценки долговой нагрузки заёмщиков и анализа формы её распределения.

Интерпретация графиков показывает, что распределение суммы кредита не является равномерным: основная масса наблюдений сосредоточена в сравнительно умеренных диапазонах, тогда как очень крупные займы встречаются значительно реже. Это типично для потребительского кредитования: массовый сегмент формируют кредиты среднего размера, а крупные суммы являются скорее исключением. Для процентной ставки характерна концентрация наблюдений в ограниченном диапазоне значений, соответствующем стандартным условиям кредитования, однако в более рискованных сегментах

наблюдается смещение распределения в сторону более высоких ставок. Это согласуется с результатами анализа по `grade` и `loan_status`.

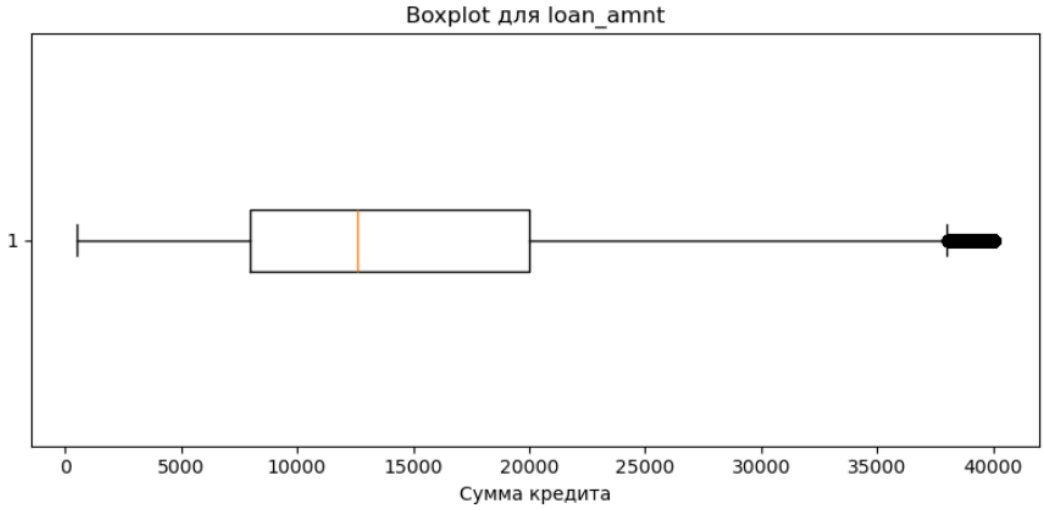

Рисунок 10 — Боксплот loan_amt

Особое внимание в работе уделено признаку `annual_inc`, поскольку он содержит сильные выбросы. Во второй части специально введён двухуровневый подход к его визуализации: сначала строится boxplot по полному диапазону, а затем — графики по основной массе наблюдений после отсечения верхнего хвоста.

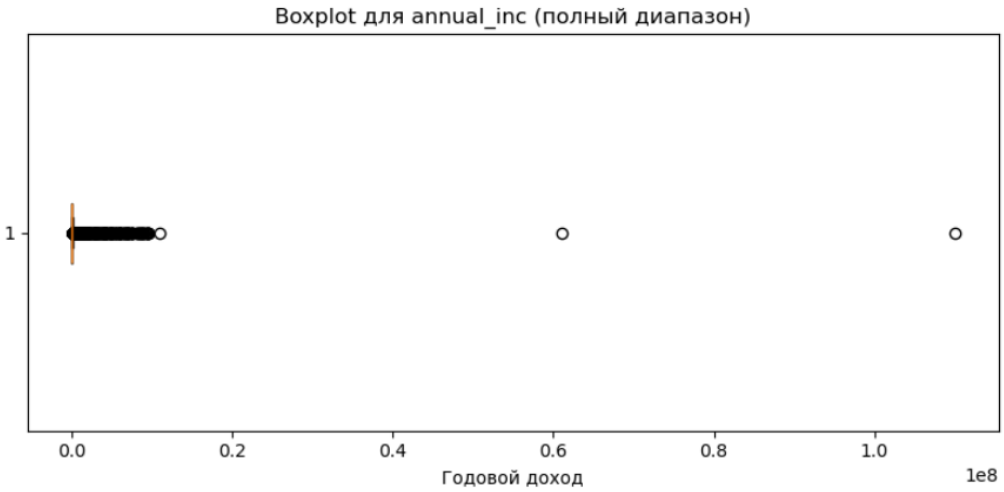

Рисунок 11 — Боксплот annual_inc

Это необходимо, поскольку наличие единичных очень больших доходов искажает масштаб оси и ухудшает читаемость графиков. Квантильный

анализ показывает, что 95-й процентиль используется как граница основной массы наблюдений, а визуализация в этом диапазоне позволяет увидеть реальную форму распределения без доминирования экстремальных значений. Таким образом, можно сделать вывод, что распределение `annual_inc` имеет выраженную правостороннюю скошенность: большинство заёмщиков сосредоточено в диапазоне сравнительно умеренных доходов, а небольшое число очень больших значений формирует длинный правый хвост.

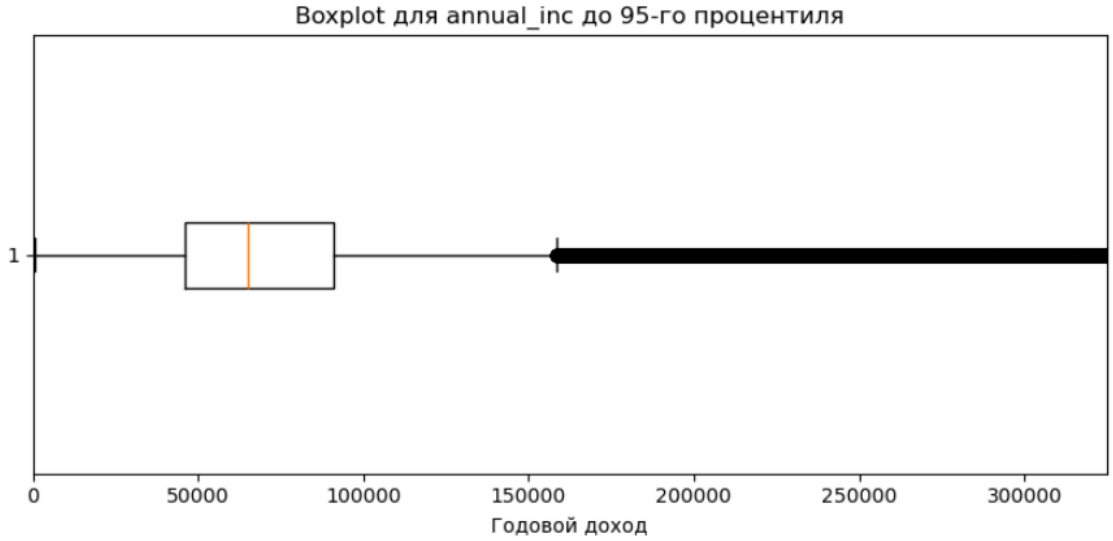

Рисунок 12 — Боксплот annual_inc 95 процентиль

Для признака `dti` распределение также имеет аналитическую ценность. В более надёжных сегментах значения `dti` в среднем ниже, тогда как у проблемных кредитов долговая нагрузка выше. Это делает `dti` важным индикатором финансовой устойчивости заёмщика: чем выше отношение долговой нагрузки к доходу, тем выше потенциальный риск просрочки или дефолта. Следовательно, количественные признаки не только описывают параметры самих займов, но и позволяют интерпретировать качество кредитного портфеля с точки зрения профиля заёмщика

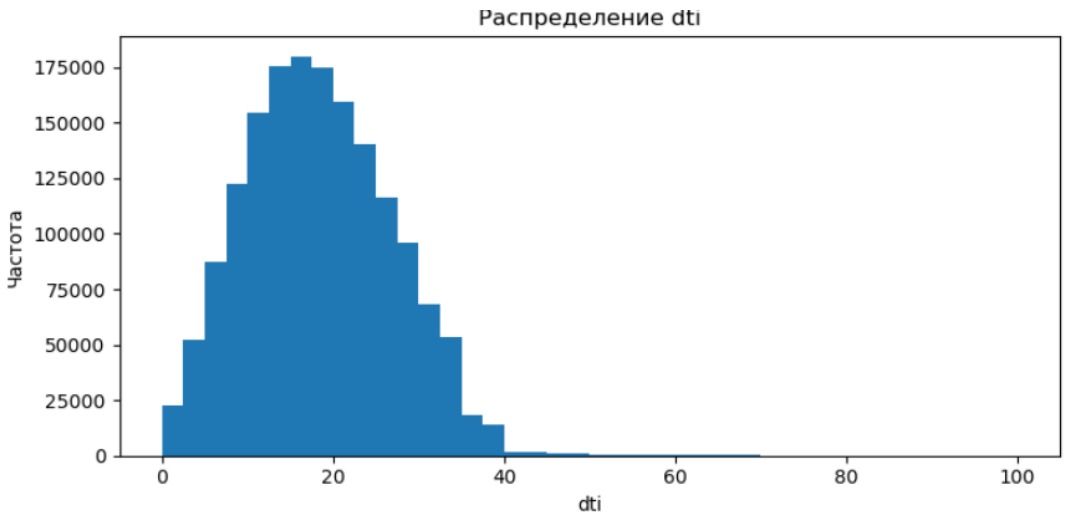

Рисунок 13 — Распределение dti

2.5 Анализ корреляционной структуры

Корреляционный анализ во второй части проводится для непрерывных количественных признаков, таких как `loan_amnt`, `int_rate`, `annual_inc`, `dti` и `term_months`. Его задача состоит в выявлении возможных линейных зависимостей между параметрами кредита и финансовыми характеристиками заёмщика.

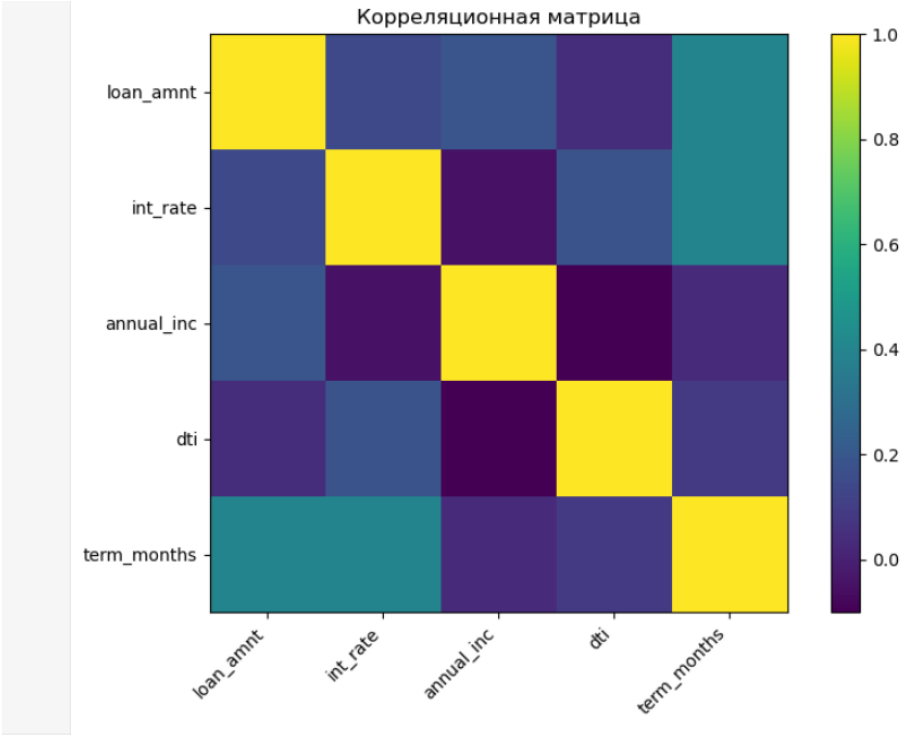

Рисунок 14 — Корреляционная матрица

2.6 Сохранение итогового результата

После завершения аналитического этапа во второй части формируется ещё одна таблица Apache Iceberg — `sobd_lab1_lending_club_processed`. Перед сохранением из набора дополнительно убираются экстремальные выбросы по `annual_inc` выше выбранного порога. Таким образом, в результате работы получается двухуровневая схема хранения: первая таблица фиксирует результат базовой подготовки, а вторая — результат более строгой аналитической фильтрации.

2.7 Выводы по второй главе

Во второй главе был выполнен расширенный разведочный анализ подготовленного датасета Lending Club Loans Data. Исследование показало, что после предварительной очистки и отбора признаков данные пригодны для

содержательного анализа по временным, категориальным, количественным и бинарным признакам. Отдельно были рассмотрены распределения суммы кредита, процентной ставки, годового дохода и долговой нагрузки, а также динамика по годам выдачи и различия между категориями `loan_status`, `grade` и `purpose`. Итогом главы стало формирование финальной таблицы `sobd_lab1_lending_club_processed`, пригодной для дальнейших аналитических задач.

ЗАКЛЮЧЕНИЕ

На первом этапе исследования были отобраны ключевые признаки, характеризующие сумму кредита, срок, процентную ставку, категорию займа, доход заёмщика, дату выдачи, статус кредита, цель займа и показатель долговой нагрузки. Далее были выполнены преобразование типов данных, формирование производных признаков и очистка от некорректных записей. Полученный набор был сохранён в таблицу `sobd_lab1_lending_club_table`, что обеспечило удобную основу для последующего анализа.

На втором этапе был проведён более глубокий разведочный анализ подготовленной таблицы. Рассмотрены динамика выдачи кредитов по годам, структура статусов займов, различия между кредитными категориями и целями кредитования, а также распределения количественных признаков. Отдельное внимание было уделено признаку `annual_inc`, содержащему выраженные выбросы, и бинарному индикатору `is_default`, использованному для оценки доли проблемных займов. Финальным результатом стало сохранение дополнительно обработанной таблицы `sobd_lab1_lending_club_processed`.

Таким образом, поставленная цель работы достигнута: реализован полный цикл подготовки и анализа большого кредитного датасета. Практический результат состоит в формировании воспроизводимого конвейера обработки данных и в получении аналитически удобного набора признаков.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Watt J. Machine Learning: Basics, Algorithms, and Application Practices. — PB BHV, 2022. — P. 640.

2. Goodfellow I., Bengio Y., Courville A. Deep Learning. — MIT Press, 2016. — P. 775. — http://www.deeplearningbook.org.

3. Chollet F. Deep Learning with Python. — Manning Publications, 2021. — P. 400.

4. Введение в машинное обучение. — 2024. — Режим доступа: `https://stepik.org/course/4852/syllabus`.

5. Géron A. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow. — 2024. — Режим доступа: `https://github.com/ageron/handson-ml`.